گزارش فاز اول: شناخت مطالعه، داده و آمار توصیفی

بهراد سلیمانیان
شماره دانشجویی: ۴۰۳۱۰۰۴۹۵
پروژه درس آمار – مسیر الف *(NHANES 2021-2023)*

آبان ۱۴۰۵

۱. سؤال آماری نهایی

آیا کاهش ساعت خواب در روزهای تعطیل/آخر هفته (*SLD013*) و پایین بودن دفعات فعالیت بدنی تفریحی، با افزایش شاخص توده بدنی در بزرگسالان ارتباط دارد؟

۲. منشأ داده و سازوکار جمع‌آوری

داده‌های این پروژه از «پیمایش ملی سنجش سلامت و تغذیه» *(NHANES)* مربوط به دوره *August 2021-2023* استخراج شده است. این داده‌ها حاصل یک **مطالعه‌ی مشاهده‌ای و مقطعی** هستند. هیچ مداخله یا آزمایش تصادفی روی افراد صورت نگرفته است و هدف، بررسی وضعیت سلامت جمعیت است.

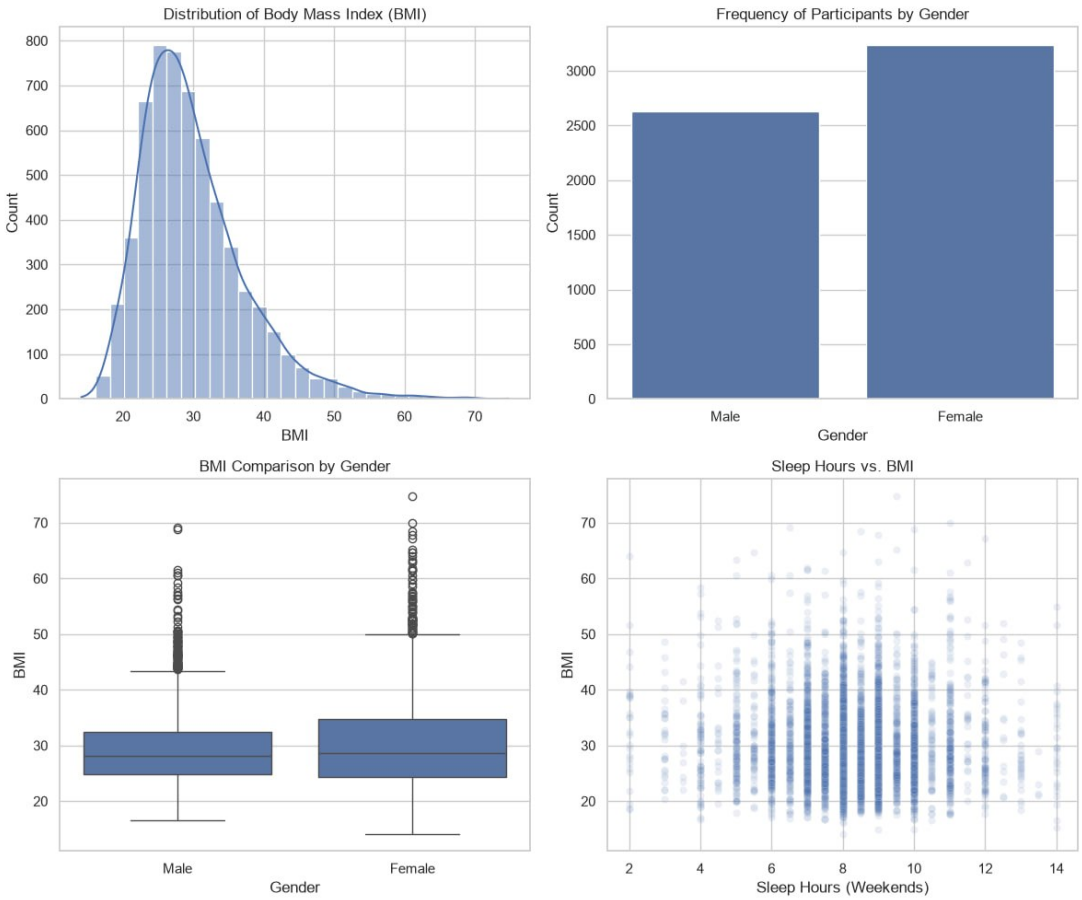
۳. ممیزی کیفیت و پاک‌سازی داده‌ها

ساختار داده‌ها به‌گونه‌ای است که برای هر فرد (*SEQN*) رکوردهای تکراری وجود ندارد (تأیید یکتایی). ممیزی زیر روی داده‌ها اعمال شد:

- تعداد کل افراد پس از ادغام اولیه فایل‌ها: ۶۳۳۷ نفر
- حذف افراد زیر ۲۰ سال (خارج از جمعیت هدف تحلیلی): ۲۷۳ نفر حذف شدند
- حذف داده‌های گمشده و کدهای امتناع/نامشخص (۷۷، ۹۹، ۷۷۷۷، ۹۹۹۹): ۱۹۹ نفر حذف شدند
- **حجم نمونه‌ی تحلیلی نهایی: ۵۸۶۵ نفر** (بزرگسال بالای ۲۰ سال با داده‌های کامل)

۴. توصیف متغیرها و مقایسه وزن‌دار

- **شاخص توده بدنی** *(BMI)*: میانگین خام *BMI* در این نمونه *29.831* است. هنگام اعمال وزن‌های معاینه (WTMEC2YR)، این میانگین به *29.683* کاهش می‌یابد. دامنه بین چارکی *(IQR)* برابر با *8.90* است.
- **سن و جنسیت:** میانگین سنی افراد در این نمونه تحلیلی برابر با *53.7* سال است. از نظر توزیع جنسیتی، *55.2%* افراد را زنان و *44.8%* را مردان تشکیل می‌دهند.
- **ساعت خواب (آخر هفته):** میانگین خام برابر با *8.25* ساعت و *IQR* آن *1.50* ساعت است.
- **فعالیت بدنی:** پس از یکسان‌سازی واحدهای اندازه‌گیری (روز/هفته/ماه)، حدود *80.1%* از نمونه تحلیلی حداقل سطح از فعالیت بدنی متوسط در هفته را گزارش کرده‌اند.



شکل ۱: توزیع شاخص توده بدنی، فراوانی جنسیت، مقایسه *BMI* بر اساس جنسیت و ارتباط اولیه خواب و *BMI*.

۵. نتیجه‌گیری ممیزی برای فازهای بعد

نمودار جعبه‌ای نشان می‌دهد که اگرچه میانه *BMI* در زنان و مردان نزدیک به هم است، اما نقاط دورافتاده *(Outliers)* با مقادیر *BMI* بسیار بالا در گروه زنان بیشتر دیده می‌شود. با توجه به ساختار مشاهده‌ای داده‌ها، نمی‌توان از ارتباطات ظاهری در نمودار پراکنش نتیجه‌ی علّی گرفت. برای تعمیم دقیق آمار به جمعیت آمریکا در فازهای استنباطی (فاز سوم)، **باید حتماً از متغیرهای وزن نمونه‌گیری (`WTINT2YR` و `WTMEC2YR`) استفاده شود** تا اثر طرح نمونه‌گیری پیچیده‌ی *NHANES* جبران گردد.