# گزارش فاز دوم: احتمال و توزیع‌های احتمالی

**بهراد سلیمانیان**
شماره دانشجویی: ۴۰۳۱۰۰۴۹۵
پروژه درس آمار – مسیر الف *(NHANES 2021-2023)*

آبان ۱۴۰۵

## ۱. تعریف رویدادها، احتمالات حاشیه‌ای و مشترک

بر اساس سؤال اصلی پروژه، رویداد «چاقی» را با شرط $BMI \geq ۳۰$ و رویداد «جنسیت مرد» را تعریف می‌کنیم.

- **احتمال حاشیه‌ای:** احتمال چاقی در نمونه برابر $P(Obese) = ۰/۴۱۱۱$ و احتمال مرد بودن $P(Male) = ۰/۴۴۷۹$ است.
- **احتمال مشترک:** احتمال اینکه فردی همزمان مرد و چاق باشد، $P(Obese \cap Male) = ۰/۱۷۱۴$ محاسبه شد.
- **بررسی استقلال:** اگر این دو رویداد مستقل بودند، حاصل‌ضرب احتمالات حاشیه‌ای باید برابر با احتمال مشترک می‌شد ($۰/۴۴۷۹ \times ۰/۴۱۱۱ = ۰/۱۸۴۱$). چون $۰/۱۷۱۴ \neq ۰/۱۸۴۱$، چاقی و جنسیت در این مجموعه داده رویدادهای مستقلی نیستند.

## ۲. احتمال شرطی، زیرگروه‌ها و قضیه بیز

احتمال چاقی با شرط کردن روی جنسیت تغییر می‌کند. در این نمونه، احتمال چاقی در مردان $P(Obese|Male) = ۰/۳۸۲۶$ و در زنان $P(Obese|Female) = ۰/۴۳۴۲$ است که نشان‌دهنده شیوع بیشتر چاقی در گروه زنان این نمونه است. با استفاده از قضیه بیز، احتمال اینکه یک فرد چاق، مرد باشد را محاسبه کردیم:

$$P(Male|Obese) = \frac{P(Obese|Male) \times P(Male)}{P(Obese)} = \frac{۰/۳۸۲۶ \times ۰/۴۴۷۹}{۰/۴۱۱۱} = ۰/۴۱۶۸$$

این مقدار دقیقاً با احتمال تجربی محاسبه شده از داده‌ها تطابق دارد.

## ۳. نقش وزن‌های نمونه‌گیری *(Survey Weights)*

احتمال تجربی خام برای چاقی ٪۴۱٫۱۱ به دست آمد. اما با اعمال وزن‌های معاینه بالینی *NHANES* (`WTMEC2YR`)، این برآورد به ٪۴۰٫۳۲ کاهش می‌یابد (اختلاف ۰٫۷۹ درصد). این تفاوت نشان می‌دهد که استفاده از وزن‌ها میزان اثرگذاری *(contribution)* هر فرد را در محاسبه نهایی تغییر می‌دهد تا نمونه نماینده دقیق‌تری از جمعیت کل باشد.

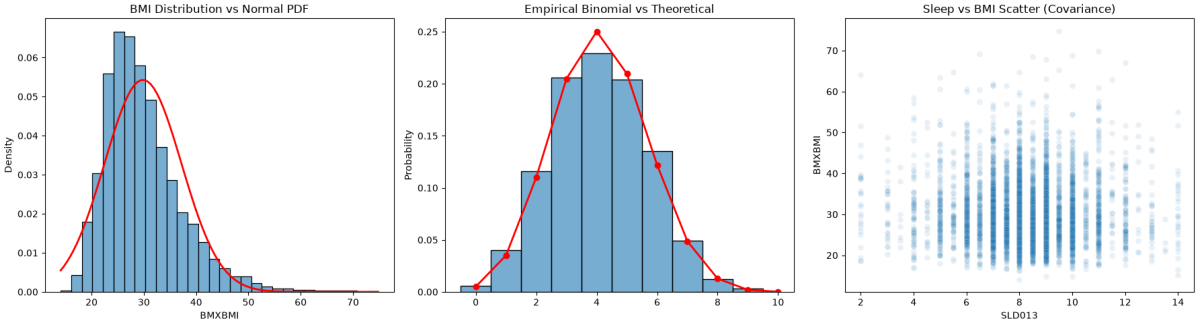
## ۴. متغیرهای تصادفی، امید ریاضی و کوواریانس

برای متغیر تصادفی پیوسته $BMI$، امید ریاضی برابر با $E[BMI] = ۲۹٫۸۳۰۵$ و واریانس آن $Var(BMI) = ۵۴٫۰۳۹۳$ محاسبه شد. برای بررسی ارتباط خواب و چاقی، کوواریانس بین ساعت خواب آخر هفته و $BMI$ برابر با $-۰/۳۸۴۸$ به دست آمد. علامت منفی کوواریانس نشان می‌دهد که یک رابطه معکوس ضعیف بین این دو وجود دارد.

## ۵. توزیع‌های احتمالی (نرمال و دوجمله‌ای)

- **توزیع متغیر پیوسته (نرمال):** تقریب نرمال در محدوده میانگین عملکرد مناسبی دارد، اما به دلیل وجود نقاط دورافتاده با مقادیر $BMI$ بسیار بالا، توزیع دارای چولگی به راست است و کاملاً نرمال نیست (شکل ۱).

- **توزیع متغیر گسسته (دوجمله‌ای):** نتایج شبیه‌سازی کامپیوتری ما تطابق بالایی با توزیع دوجمله‌ای نظری دارد، زیرا شبیه‌سازی با جایگذاری و با احتمال ثابت انجام شده است. اما در دنیای واقعی، تقریب دوجمله‌ای برای افراد *NHANES* کاملاً صادق نیست؛ زیرا فرض‌های دوجمله‌ای (استقلال کامل مشاهدات و احتمال یکسان برای همه) در طرح نمونه‌گیری پیچیده و خوشه‌ای *NHANES* نقض می‌شود (افراد یک خوشه جغرافیایی یا خانوار ممکن است احتمالات مشابهی داشته باشند).




**شکل ۱:** (چپ) تقریب توزیع $BMI$. (وسط) توزیع تجربی رویداد چاقی. (راست) نمودار پراکنش خواب و $BMI$.

## ۶. جدول خلاصه احتمالات

| گروه | احتمال برآورد شده | گروه | احتمال برآورد شده |
|---|---|---|---|
| احتمال حاشیه‌ای چاقی (کل) | ۰٫۴۱۱۱ | احتمال حاشیه‌ای مردان | ۰٫۴۴۷۹ |
| احتمال شرطی چاقی (مردان) | ۰٫۳۸۲۶ | احتمال شرطی چاقی (زنان) | ۰٫۴۳۴۲ |